



T.C
GEBZE TEKNİK ÜNİVERSİTESİ

**HİPERSPEKTRAL VE LİDAR UZAKTAN ALGILANMIŞ GÖRÜNTÜLERİN
BİRLEŞİMİNE DAYALI GÖRÜNTÜ SINIFLANDIRMA**

Efkan DURAKLI

Danışman

Doç. Dr. Erchan APTOULA

Ocak, 2019

Gebze, KOCAELİ



T.C
GEBZE TEKNİK ÜNİVERSİTESİ

**HİPERSPEKTRAL VE LİDAR UZAKTAN ALGILANMIŞ GÖRÜNTÜLERİN
BİRLEŞİMİNE DAYALI GÖRÜNTÜ SINIFLANDIRMA**

Efkan DURAKLI

Danışman

Doç. Dr. Erchan APTOULA

Ocak, 2019

Gebze, KOCAELİ

Bu çalışma/....../200.. tarihinde ařağıdaki jüri tarafından Bilgisayar Mühendisliğı Bölümünde Lisans Bitirme Projesi olarak kabul edilmiştir.

Bitirme Projesi Jürisi

Danışman Adı		
Üniversite		
Fakülte		

Jüri Adı		
Üniversite		
Fakülte		

Jüri Adı		
Üniversite		
Fakülte		

ÖNSÖZ

Bu kılavuzun ilk taslaklarının hazırlanmasında emeği geçenlere, kılavuzun son halini almasında yol gösterici olan Sayın Doç. Dr. Erchan APTOULA hocama ve bu çalışmayı destekleyen Gebze Teknik Üniversitesi'ne içten teşekkürlerimi sunarım.

Ayrıca eğitimim süresince bana her konuda tam destek veren aileme ve bana hayatlarıyla örnek olan tüm hocalarıma saygı ve sevgilerimi sunarım.

Ocak, 2019

Efkan DURAKLI

İÇİNDEKİLER

ÖNSÖZ	vi
ŞEKİL LİSTESİ	viii
TABLO LİSTESİ	ix
KISALTMA LİSTESİ	x
ÖZET	xi
SUMMARY	xii
1. GİRİŞ	xiii
1.1. PROJENİN AMACI	xiii
1.2. RAPORUN AKIŞI.....	xiii
1.3. HİPERSPEKTRAL GÖRÜNTÜLEME	xiv
1.4. LİDAR	xv
1.5. PROJE KAPSAMINDA KULLANILAN VERİ KÜMESİ	xvi
1.5.1. Houston Üniversitesi Veri Kümesi	xvi
2. SINIFLANDIRMA İÇİN KULLANILAN MAKİNE ÖĞRNMESİ YÖTEMLERİ	xviii
2.1. K EN YAKIN KOMŞU SINIFLANDIRMA YÖNTEMİ.....	xviii
2.2. RASTGELE ORMAN SINIFLANDIRMA YÖNTEMİ	xviii
3. HİPERSPEKTRAL VERİ BOYUTUNU AZALTMA YÖNTEMLERİ	xix
3.1. Temel Bileşenler Analizi (Principal Component Analysis)	xix
4. YAPAY SİNİR AĞLARI	xix
4.1. YAPAY SİNİR AĞI NEDİR	xix
4.2. TAM BAĞLI SİNİR AĞI.....	xx
4.3. EVRİŞİMSEL SİNİR AĞLARI	xxi
5. PROJE GEREKSİNİMLERİ.....	xxii
6. LİTERATÜR TARAMASI	xxii
7. METOD.....	xxiii
7.1. TEMEL BİLEŞEN ANALİZİ.....	xxiii
7.2. SPEKTRAL BİLGİ KULLANILARAK YAPILAN SINIFLANDIRMALAR	xxiv
7.3. SPEKTRAL VE UZAMSAL VERİ BERABER KULLANILARAK YAPILAN SINIFLANDIRMALAR ...	xxv
8. DENEYSEL SONUÇLARI.....	xxvi
9. TARTIŞMA.....	xxvii
10. KAYNAKLAR	xxviii

ŞEKİL LİSTESİ

Şekil 1-1: Temsili bir Hiperspektral Veri Küpü ve Farklı Piksellerde Yer Alan Farklı Nesnelerin Spektral İmzaları	xiv
Şekil 1-2: LiDAR yükseklik değerlerinin gösterildiği örnek bir yükseklik haritası.....	xv
Şekil 1-3: (a) Houston verisinin sahte KYM ile gösterimi. (b) Eğitim veri kümesi noktaları ve sınıf-renk ilişkisi. (c) Test veri kümesi noktaları ve sınıf-renk ilişkisi.(d) Eğitim ve test verilerinin birlikte gösterimi (yeşil: eğitim kümesi, kırmızı: test kümesi). (e) Renk-sınıf ilişkisi. (f) Houston Üniversitesi LiDAR yoğunluk değerleri görseli.....	xvii
Şekil 4-1: İki Gizli Katmanlı Yapay Sinir Ağı.....	xx
Şekil 4-2: Yerel Alıcı Alan Gösterimi.....	xxi
Şekil 7-1: Houston Üniversitesi Hiperspektral Görüntüsünün TBA'dan sonraki temel bileşenlerin varyansını gösteren grafik.....	xxiii
Şekil 7-2: Sınıflandırma için tasarlanan CNN ağı görseli.....	xxv

TABLO LİSTESİ

Tablo 1-1: Houston Üniversitesi Veri Kümesi İçeriği.....	xvi
Tablo 7-1: Sınıflandırma İçin Tasarlanan Tam Bağlı Sinir Ağı Tasarımı.....	xxiv
Tablo 8-1: KNN sınıflandırıcısı deney sonuçları.....	xxvi
Tablo 8-2: Rastgele Orman sınıflandırıcı deney sonuçları.....	xxvi
Tablo 8-3: Tam Bağlı Sinir Ağı deney sonuçları	xxvi
Tablo 8-4: Yama Tabanlı CNN deney sonuçları.....	xxvi

KISALTMA LİSTESİ

HSG :	Hiperspektral Görüntü
LiDAR:	Light Detection and Ranging (Işık İle Algılama ve Menzil Tayini)
DESA:	Derin Evrişimsel Sinir Ağları
KNN:	K Nearest Neighbour (K En Yakın Komşu)
RO:	Rastgele Orman
YSA:	Yapay Sinir Ağları
CNN:	Convolutional Neural Networks (Evrişimsel Sinir Ağları)
OA:	Overall Accuracy – Genel Doğruluk Oranı
AA:	Average Accuracy – Ortalama Doğruluk Oranı

ÖZET

Gelişen yeni nesil uzaktan algılama teknolojisi ile birlikte, elektromanyetik spektrumda yüzlerce farklı dalga boyundan görüntü alınabilmektedir. Bu verilere ek olarak ışık ile algılama teknolojisi ile uzaktaki nesneler ile algılayıcı arası mesafe tayin edilebilmektedir. İki farklı kaynaktan elde edilen bu bilgiler bir bölgeye ait anlamsal bölütleme çözümlemesine girdi oluşturulmaktadır.

Bu proje ile HSG (Hiperspektral Görüntü) ve LiDAR (Light Detection and Ranging – Işık ile Algılama ve Menzil Tayini) verisi bulunan bölgeye ait veri kümesinin anlamsal bölütlemesinin yüksek başarımla gerçekleştirilmesi amaçlanmıştır.

Projede öncelikle sadece spektral bilgi kullanılarak sınıflandırma işlemi gerçekleştirilmiştir. Bu yöntem yapılırken, sadece hiperspektral veri kullanılarak ve hiperspektral veriyle birlikte LiDAR verisi de kullanılarak sınıflandırma işlemleri ayrı ayrı gerçekleştirilmiştir. Hiperspektral veri ile birlikte LiDAR verisi de kullanılarak gerçekleştirilen sınıflandırmanın daha yüksek başarımla elde ettiği görülmüştür.

Bu projede ayrıca, uzamsal veriyi de kullanabilmek için yama tabanlı CNN yöntemiyle sınıflandırma işlemleri gerçekleştirilmiştir. Uzamsal veriyi kullanarak yapılan deneyler başarımlarının arttığını göstermiştir.

Hiperspektral ve LiDAR verisinin beraber kullanıldığı farklı birleştirme yöntemleri denenmiştir. Kullanılan birleştirme yönteminin sınıflandırmanın başarımlarını büyük oranda etkilediği görülmüştür.

Bu çalışma sonucunda Hiperspektral veri ile birlikte LiDAR verisinin de kullanılmasının, sınıflandırma başarımlarını büyük oranda artırdığı ve spektral ve uzamsal verinin bir arada kullanılmasını sınıflandırma başarımlarını büyük oranda etkilediği görülmüştür. Ayrıca, kullanılan tümleştirme yönteminin de sınıflandırma başarımlarını büyük oranda etkilediği görülmüştür.

Anahtar Kelimeler: Hiperspektral Görüntüleme, LiDAR, Anlamsal Bölütleme, CNN

SUMMARY

With the evolving next generation remote sensing technology, hundreds of different wavelength images can be captured in the electromagnetic spectrum. In addition to this, light sensing technology can be used to determine distances between objects and distant objects. This information obtained from different sources constitutes an input to the analysis of the semantic segmentation of a region.

In this project, firstly classification is performed using spectral information. When performing this method, only hyperspectral data and the hyperspektral data with the LiDAR data were used for classification. The classification using hyperspectral data as well as LiDAR data showed higher classification performance.

Further, in order to spatial information, classification is performed using patch-based CNN method. Experiments using spatial data showed that the performance rate increased.

Experiments are performed that are using different fusion of hyperspectral and LiDAR methods. Experiments hhow that the method of fusion used siginificantly affects accuracy of classification.

As a result of this study, the use of hypersperspectral data together with LiDAR data greatly increased the accuracy of classification and the combinaiton of spectral and spatial data sginificantly affected the performance rate of classification. In addition, it was observed that the fusion method used has a significant affect on the classification performance rate.

Keywords: Hyperspectral Imaging, LiDAR, Semantic Segmentaion, CNN

1. GİRİŞ

1.1. PROJENİN AMACI

Belirli bir alan için çekilmiş görüntüdeki piksellerin sınıflandırılması araştırmacıların üzerinde çalıştığı popüler bir problemdir. Bu görüntüler genellikle yüzlerce farklı dalga boyundaki görüntülerin bir araya getirilerek elde edildiği hiperspektral görüntülerdir. Hiperspektral görüntü sayesinde farklı maddelerden yapılmış malzemeler birbirinden kolaylıkla ayrılabilir. Fakat, aynı maddeden yapılmış faklı sınıfları ayırt etmede ve gölgelik alanlarda kalan piksellerin sınıflandırılmasında hiperspektral veri kullanılarak yapılan sınıflandırma beklenen sonucu verememektedir. Bu problemin üstesinden gelebilmek için, aynı alan için çekilmiş LiDAR verisi de hiperspektral verilere ek olarak kullanılmaktadır. LiDAR verisi çekildiği alanın yükseklik bilgisini verir ve gölgelik alanlardan etkilenmez. Bu sayede aynı maddeden yapılmış, farklı yükseklik değerlerine sahip sınıflar ve gölgelik alanlarda kalan sınıflar birbirinden kolaylıkla ayırt edilebilmektedir. Bu projenin amacı, belirli bir alan için çekilmiş hiperspektral görüntüdeki piksellerin, o alan için çekilmiş LiDAR görüntülerini de kullanarak anlamsal bölütlemesini yapmaktır.

1.2. RAPORUN AKIŞI

Bölüm 1’de projenin amacı, proje kapsamında kullanılan veri kümesi içeriği ve bilgilendirmesi, hiperspektral görüntüleme ve LiDAR hakkında bilgi verilmiştir.

Bölüm 2’de bu projede sınıflandırma için kullanılan makine öğrenmesi yöntemlerinden bahsedilmiştir.

Bölüm 3’te proje kapsamında kullanılan boyut azaltma yöntemlerinden olan Temel Bileşen Analizinden bahsedilmiştir.

Bölüm 4’te yapay sinir ağlarından bahsedilmiştir.

Bölüm 5’te proje gereksinimlerinden bahsedilmiştir.

Bölüm 6’da Houston Üniversitesi Veri kümesi üzerine yapılan çalışmalardan bahsedilmiştir.

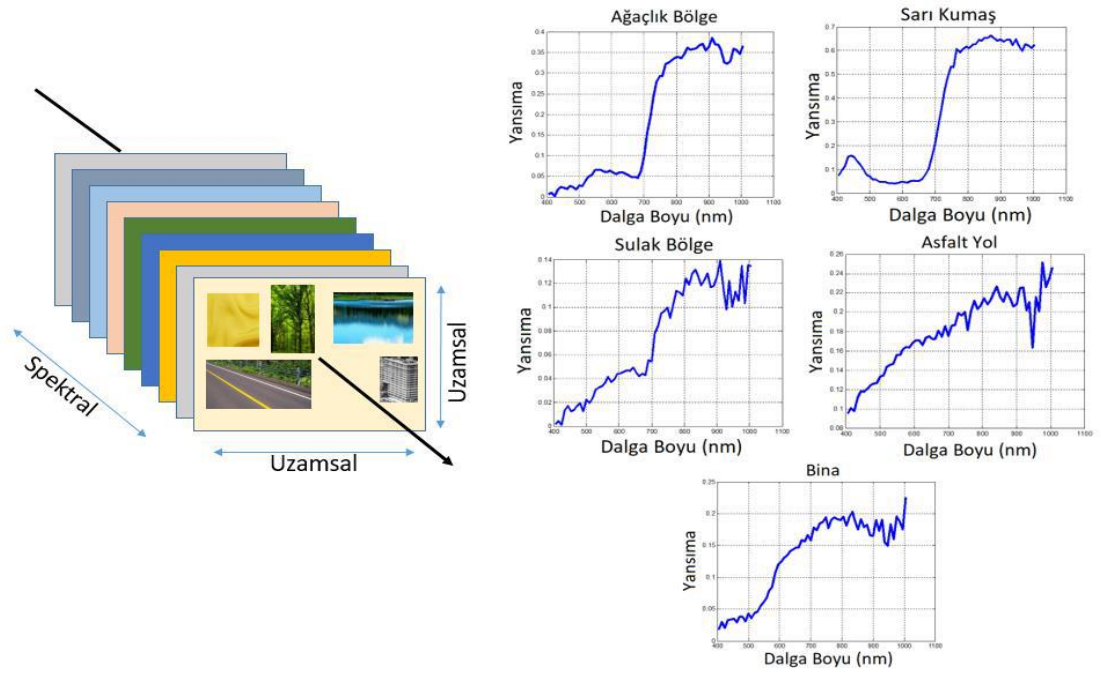
Bölüm 7’de gerçekleştirilen metotlardan bahsedilmiştir.

Bölüm 8,de yapılan deneyin sonuçları verilmiştir.

Bölüm 9, projenin eksiklerinden ve projede yapılabilecek geliştirilmelerden bahsedilmiştir.

1.3. HİPERSPEKTRAL GÖRÜNTÜLEME

‘Hiper’ ve ‘spektral’ kelimelerinden oluşan ‘hiperspektral’ çok sayıda spektral banttıan oluřan anlamına gelmektedir. Multispektral görüntülemeden temel farkı ise çok daha fazla bantta ölçüm alınması ve buna ek olarak bantların aralığının dar ve birbirine yakın olmasıdır. Hiperspektral kameralar ile alınan ölçümlerde, her bir materyalin farklı dalga boylarında ışığı farklı şekilde yansıtmasına bağı olarak, o materyallere ait spektral imzalar çıkartılır ve görüntü içerisinde yer alan her bir pikselin hangi materyali içerdiği tespit edilir. Hiperspektral görüntüler “hiperküp” olarak adlandırılan bir yapıda tutulmaktadır. Temsili bir hiperküp ve görüntüde yer alan piksellerin içerdiği materyaller ve materyalin spektral imzası Şekil 1-1’de verilmektedir.




Şekil 1-1: Temsili bir Hiperspektral Veri Küpü ve Farklı Piksellerde Yer Alan Farklı Nesnelerin Spektral İmzaları

1.4. LiDAR

LiDAR (Light Detection and Ranging), günümüzde çok farklı amaçlar için aktif olarak kullanılan, bir uzaktan algılama teknolojisidir. Kaynak olarak genellikle lazer kullanılmaktadır. Kendi ışık kaynağını kullandığı için gölgelerden etkilenmez. Kaynaktan gönderilen lazer ışınının gidiş-dönüş süresi kaydedilerek objelerin mesafelerinin ölçülmesi sağlanır. Bu sayede, uzaktan çekilmiş bir alanın, yükseklik haritası elde edilebilmektedir. LiDAR verileri; jeolojiden hidrolojiye, haritacılıktan askeri uygulamalara kadar birçok alanda kullanılmaktadır.

Hiperspektral görüntülere ek bilgi sağlaması nedeniyle LiDAR verilerinin anlamlandırılması büyük önem taşımaktadır. Örneğin, asfalt yol ile kiremit çatı malzemelerinin hiperspektral materyal yapıtaşlarının benzerliğinden dolayı büyük benzerlik göstermektedir. Ancak iki farklı sınıfta yer alan bu nesnelerin LiDAR verileri incelendiğinde, bu veriler yeryüzünde bulundukları konum itibari ile farklılık göstermekte ve hiperspektral verilere ek bilgi sağlamaktadır. Şekil 1-2’ de örnek bir LiDAR yüksekli haritası görseli verilmektedir.



Şekil 1-2: LiDAR yükseklik değerlerinin gösterildiği örnek bir yükseklik haritası

1.5. PROJE KAPSAMINDA KULLANILAN VERİ KÜMESİ

1.5.1. Houston Üniversitesi Veri Kümesi


IEEE(Institute of Electrical and Electronics Engineers) Yer Bilimleri ve Uzaktan Algılama topluluğunun 2013 yılında düzenlediği bir yarışmada sağlanan bu veri kümesi ABD'nin Houston Üniversitesi bölgesinin çevresinden elde edilmiştir. 349x1905 uzamsal çözünürlüğe sahip hiperspektral görüntüde 380 nm ile 1050 nm dalga boyu aralığında 144 farklı spektral ban bulunmaktadır. Hiperspektral verilere ek olarak LiDAR yükseklik ve yoğunluk verileri de bu veri kümesi içeriğinde sağlanmıştır. Veri kümesi 15 farklı sınıfa ait eğitim ve test verileri içermektedir. Eğitim ve test verilerinin örnek sayıları ve sınıf bilgileri Tablo 1'de verilmektedir. Houston veri kümesinin şekil olarak ifadesi Şekil 1-3'de verilmektedir.

Sınıf Numarası	Sınıf Adı	Eğitim Verisi Miktarı	Test Verisi Miktarı
1	Sağlıklı Çimen	198	1053
2	Ezilmiş Çimen	190	1064
3	Yapay Çimen	192	505
4	Ağaç	188	1056
5	Toprak	186	1056
6	Su	182	143
7	Eysel Bölge	196	1072
8	İşyeri Bölgesi	191	1053
9	Asfalt Yol	193	1059
10	Otoyol	191	1036
11	Tren Yolu	181	1054
12	Otopark1	192	1041
13	Otopark2	184	285
14	Tenis Kortu	181	247
15	Koşu Yolu	187	473


Tablo 1-1 : Houston Üniversitesi Veri Kümesi İçeriği



(a)




(b)



(c)

	Sağlıklı Çimen		Su		Tren Yolu
	Ezilmiş Çimen		Eysel Bölge		Otopark 1
	Yapay Çimen		İşyeri Bölgesi		Otopark 2
	Ağaç		Asfalt Yol		Tenis Kortu
	Toprak		Otoyol		Koşu Yolu

(e)



(f)

Şekil 1-3: (a) Houston verisinin sahte KYM ile gösterimi. (b) Eğitim veri kümesi noktaları ve sınıf-renk ilişkisi. (c) Test veri kümesi noktaları ve sınıf-renk ilişkisi. (d) Eğitim ve test verilerinin birlikte gösterimi (yeşil: eğitim kümesi, kırmızı: test kümesi). (e) Renk-sınıf ilişkisi. (f) Houston Üniversitesi LiDAR yoğunluk değerleri görseli.

2. SINIFLANDIRMA İÇİN KULLANILAN MAKİNE ÖĞRNMESİ YÖTEMLERİ

2.1. K EN YAKIN KOMŞU SINIFLANDIRMA YÖNTEMİ

K-NN algoritması, T.M Cover ve P.E Hart tarafından önerilen, örnek veri noktasının bulunduğu sınıfın ve en yakın komşunun, k değerine göre belirlediği bir sınıflandırma yöntemidir. Bu algoritma en iyi bilinen, eski, basit ve etkili örüntü sınıflandırma yöntemlerinden biridir ve makine öğrenmesi algoritmaları arasında popüler olarak kullanılmaktadır.

K-NN algoritması, eğitiminin olmaması, gerçekleştiriminin kolay, analitik olarak izlenebilir, yerel bilgilere uyarlanabilir, paralel gerçekleştirime uygun, gürültülü eğitim verilerine karşı dirençli olması gibi avantajları ile sınıflandırma uygulamalarında özellikle tercih edilmektedir. Bu avantajlara rağmen, yüksek miktarda bellek alanına gereksinim duyması, veri seti ve öznitelik boyutu arttıkça işlem yükünün ve maliyetin önemli ölçüde yükselmesi, performansın k komşu sayısı, uzaklık ölçütü ve öznitelik sayısı gibi parametre ve özelliklere bağlı olarak etkilenmesi gibi birtakım dezavantajları da beraberinde getirmektedir.

2.2. RASTGELE ORMAN SINIFLANDIRMA YÖNTEMİ

RO, 2001 yılında Leo Breiman tarafından geliştirilmiştir. RO algoritması, 1996 yılında geliştirdiği Torbalama (bagging) yöntemi ve Kim Ho tarafından geliştirilen Rastgele Altküme yöntemlerinin birleşimidir. Amit ve Geman tarafından 1997’de tanımlanan, her düğüm için en iyi ayrımın rastgele bir seçim üzerinden belirlendiği bir çalışmadan da etkilenmiştir.

RO, denetimli bir sınıflandırma algoritmasıdır. Sınıflandırma işlemi esnasında birden fazla karar ağacı üreterek sınıflandırma değerinin yükseltmeyi hedefleyen bir algoritmadır. Bireysel olarak oluşturulan karar ağaçları bir araya gelerek, karar ormanı oluşturur. Buradaki karar ağaçları, veri setinden rastgele seçilmiş birer alt kümedir. Astronomi, biyomedikal, kontrol sistemleri, finans analizi ve sağlık gibi birçok alanda uygulanmaktadır.

3. HİPERSPEKTRAL VERİ BOYUTUNU AZALTMA YÖNTEMLERİ

3.1. Temel Bileşenler Analizi (Principal Component Analysis)


TBA, orijinal p değişkeninin varyans yapısını daha az sayıda ve bu değişkenlerin doğrusal bileşenleri olan yeni değişkenlerle ifade etme yöntemidir. Aralarında korelasyon bulunan p sayıda değişkeni açıkladığı yapıyı, aralarında korelasyon bulunmayan ve sayıca orijinal değişken sayısından daha az sayıda ($p > k$) orijinal değişkenlerin doğrusal bileşenlerini bulmak için kovaryans matrisinin ya da korelasyon matrisinin öz değerleri ve öz vektörleri kullanılır. Veri matrisinde yer alan p değişkeninin doğrusal bileşenlerini bulmak için kovaryans matrisinin ya da korelasyon matrisinin öz değerleri ve öz vektörleri kullanılır. Eğer değişkenler aynı birim veya karşılaştırılabilir birimlerdeyse, değişken varyansları aynı boyuttaysa varyans-kovaryans matrisi kullanılır. Bu durumlar sağlanmadığında varyans-kovaryans matrisi yerine korelasyon matrisi kullanılır.

4. YAPAY SİNİR AĞLARI

4.1. YAPAY SİNİR AĞI NEDİR

Yapay sinir ağları basit biyolojik sinir sisteminin çalışma şeklinden esinlenerek tasarlanan makine öğrenmesi yaklaşımıdır. Temek olarak girdi katmanı, ara katman ve çıktı katmanlarında oluşan yapay sinir ağları; ağırlıklandırılmış şekilde birbirlerine bağlanmış birçok işlem biriminden (nöronlar) oluşan matematiksel sistemlerdir.

Sinir ağları katmanlara bağlı nöronların bir yapısı olarak modellenmiştir. İleri beslemeli yapay sinir ağı modelinde; belirli bir katmanın nöronlarının çıktıları, bir sonraki katmanın girdilerini bağlantı ağırlıkları ile oluşturur. Girdi her zaman ileri doğru (aktivasyon yönü) iletilmektedir. Bu yüzden aynı katmanda yer alan katmanlar ise ara katman ya da gizli katman olarak adlandırılmaktadır. Tipik bir gizli katmana sahip YSA modeli Şekil 4-1’de verilmiştir. YSA modeline bağlı olarak; ilk katmanlarda girdi sinyalinden basit bilgiler çıkarılırken ikinci ve üçüncü gizli katmanlarda ise veri kümesine özel detaylı bilgiler çıkarılmaktadır. Derin sinir ağları yapılarında ilgili derinliği sağlayan katmanlar gizli katmanlardır. Gizli katmanların sayısının artması durumunda oluşturulan sinir ağı modeli daha derin ve karmaşıklığı artan bir yapıya dönüşmektedir. Buna ek olarak oluşturulan gizli katmanda yer alan nöron sayısı da YSA başarımını ve karmaşıklığını etkileyen önemli parametrelerden bir tanesidir.



Şekil 4-1 : İki gizli katmanlı Yapay Sinir Ağı

4.2. TAM BAĞLI SİNİR AĞI

Tam bağlı katmandaki nöronlar bir önceki katmandaki tüm etkinleşmelere tam bağlantılara sahiptir ve üretilen aktivasyon haritalarına dayalı büyük sınıflandırma işleminden büyük sınıflandırma işleminde sorumludurlar. Bu katmanda ileri besleme esnasında oluşan matematiksel ifade aşağıdaki denklem ile verilmektedir.

$$u_i^l = \sum w_{ji}^{l-1} y_j^{l-1}$$

$$y_i^l = f(u_i^l) + b^{(l)}$$


Bu denklemde yer alan $l, (l-1)$ katman numarası, i, j ise nöron numarasını, y_i^l oluşturulan çıktı katmanındaki değeri, w_{ji}^{l-1} gizli katmanda yer alan ağırlık değerini, y_j^{l-1} girdi nöronlarının değerlerini, u_i^l aktivasyon fonksiyonu öncesi çıktı katmanı değeri ve $b^{(l)}$ ise sapma değerini vermektedir. Burada belirtilen $f(.)$ fonksiyonu ise aktivasyon fonksiyonunu ifade etmektedir.

4.3. EVRİŞİMSEL SİNİR AĞLARI

Günümüzde evrişimsel sinir ağı ve derin öğrenme tabanlı çözümler pek çok sorunda iyi sonuçlar vermektedir. Görüntü tanıma, ses tanıma ve doğal dil işleme gibi birçok farklı alanda uygulanabilmektedir. Özellikle görünür bantta elde edilmiş görüntülerin sınıflandırılmasında; olgun, başarılı ve popüler yöntem olan DESA modeli resim üzerinde bir pikseli sınıflandırmaktan ziyade imgeyi genel olarak sınıflandırmaya yönelik çalışmalarda kullanılmıştır.

Derin evrişimsel sinir ağlarında; girdi katmanı, evrişim katmanı, havuzlama katmanı, tam bağlı katman ve çıktı katmanı gibi katmanlar yer almaktadır. Ancak evrişimsel sinir ağı genellikle belirli bileşenler grubundan oluşmaktadır. Bu bileşenler, soruna göre özelleştirilmekte ve bahsi geçen bütün katmanları içermeyebilmektedir. Derin evrişimsel sinir ağı temel olarak 3 yaklaşıma sahiptir.

1-) Yerel Alıcı Alanlar (Local Receptive Fields): Girdi sinyali ile gizli evrişim katmanında yer alan filtreler bölgesel alanlarda Şekil 4-2’de gösterilen şekilde bağıllık kurmaktadır. Bağıllık kurulan bu alanlar ise yerel alıcı alan olarak adlandırılmaktadır. Her bir yerel alıcı alanın evrişim katmanında sonuç oluşturduğu bir nöron bulunmaktadır.



Şekil 4-2: Yerel Alıcı Alan Gösterimi

2-) Paylaşılan Ağırlıklar (Shared Weights) : Evrişimsel sinir ağlarında her bir evrişim filtresine özel bir öznitelik haritası oluşmaktadır. Bu öznitelik haritası oluşturulurken imgenin bütün bölgesinden benzer özellikleri çıkaran filtreler kullanılmaktadır. Evrişim filtresinde yer alan parametreler ise paylaşılan ağırlık değerleri olarak adlandırılmaktadır. Evrişimsel sinir ağı tarafından sağlanan bu özellik ile öğrenilen serbest parametre sayısı büyük ölçüde azaltılmaktadır. Bu sayede model üzerinde daha iyi bir genelleme sağlanabilmektedir.

3-) Alt Örneklem: Alt örneklem katmanında ise öznitelik haritalarının çözünürlüğü düşürülmektedir.

5. PROJE GEREKSİNİMLERİ

Bu projede hedeflenenler :

- Hiperspektral görüntülerin okunabilmesi için gerekli kütüphanelerin araştırılıp, kurulması.
- Sınıflandırma gerçeklemek için gerekli makine öğrenmesi kütüphanelerin araştırılıp kurulması.
- Derin Sinir Ağlarını eğitebilmek için gerekli GPU'nun sağlanması.
- Hiperspektral ve LiDAR verilerini bir arada kullanarak en yüksek sınıflandırma sonucunu elde edebilmek için gerekli deneylerin gerçekleştirilmesi
- Sınıflandırmada sonucunun kappa değerinin en az 0.9 olması.
- Hiperspektral ve LiDAR verilerini birleştirme yöntemlerinin geliştirilmesi.
- Houston veri kümesinin etiketlenmesinin 5 dk altında yapılması.

6. LİTERATÜR TARAMASI

Houston veri kümesi üzerinde oldukça yüksek sayıda çalışma gerçekleştirilmiştir. Genel olarak yapılan çalışmalarda LiDAR ve hiperspektral verilerinin kaynaştırılması ve sınıflandırma işleminin yapılmasından önce bu verilerden uzamsal ve biçimsel özniteliklerin çıkarılması gerçekleştirilmiştir.

Liao vd. tarafından gerçekleştirilen çalışmada, çizge temelli yaklaşım ile LiDAR ve hiperspektral veriden biçimsel yöntemlerle çıkarılan öznitelikler tümleştirilmiştir. Sınıflandırıcı olarak DVM kullanılmış test veri kümesinde %94 oranında başarımlı sağlamıştır.

Khodadadzadeh vd. tarafından gerçekleştirilen çalışmada EMAP yöntemi ile LiDAR ve HSG'lerden morfolojik profiller çıkarılmıştır. Alt uzay çok terimli lojistik regresyon (MLRsub) ile sınıflandırma işlemi ile sınıflandırma gerçekleştirilmiştir. Test verisi üzerinde %92.05 başarımlı oranı yakalanmıştır

Aytaylan vd. çalışmasında semantik bölütleme algoritması ile iki terimden oluşan tekli enerjili ve ikili enerjili yeni bir enerji fonksiyonu önerilmiştir. HySime algoritması ile boyut indirgemesinin önerildiği çalışmada enerji fonksiyonları tümleştirme için kullanılmış ve DVM ile sınıflandırma gerçekleştirilmiştir. Başarımlı %89.87'ye ulaştığı belirtilmiştir .


Salman vd. tarafından gerçekleştirilen çalışmada hiperspektral görüntülerinden ve LiDAR görüntülerinden biçimsel profil haritaları üretilmiş, ardından bu spektral veriler ve biçimsel profiller boyutsal olarak birleştirilmiştir. Başarımın, %93.97'ye ulaştığı belirtilmiştir.

Ghamisi vd. tarafından gerçekleştirilen çalışmada, hiperspektral ve LiDAR görüntüleri için iki ayrı CNN ağı tasarlanarak bu ağlardan elde edilen biçimsel özellikler tam bağlı bir sinir ağına verilerek son sınıflandırma işlemi gerçekleştirilmiştir. Başarımın %91.32 olduğu belirtilmiştir.

7. METOD

7.1. TEMEL BİLEŞEN ANALİZİ

Hiperspektral görüntüdeki gereksiz tekrarlanan verileri atmak için TBA yapıldı. Hiperspektral verilere uygulanan TBA sonucu oluşan ilk 3 temel bileşenin kümülatif varyansın %99'undan fazlasını temsil ettiği görülmüştür. TBA işleminden sonraki ilk 10 temel bileşenin varyansını gösteren grafik Şekil 7-1'de verilmiştir.



Şekil 7-1 : Houston Hiperspektral Görüntüsünün TBA'dan sonraki temel bileşenlerin varyansını gösteren grafik.

7.2. SPEKTRAL BİLGİ KULLANILARAK YAPILAN SINIFLANDIRMALAR

Bu aşamada sınıflandırma işleminin gerçekleştirilmesi için sadece hiperspektral veri kullanılmış, uzamsal veri dikkate alınmamıştır.

Sınıflandırma işlemi için KNN, RO ve Tam Bağlı Sinir ağı yöntemleri kullanılmıştır. Bu sınıflandırıcılara girdi olarak farklı özellik vektörleri verilerek sonuçlar kaydedilmiştir. Girdi olarak verilen özellik vektörleri şu şekildedir.

- Hiperspektral görüntüdeki her bir pikselin 144 farklı dalga boyundaki değerini içerek özellik vektörü
- Hiperspektral özellik vektörüne LiDAR verisi de eklenerek elde edilen 145 uzunluğunda elde edilen özellik vektörü
- Hiperspektral veriye temel bileşen analizi yapıldıktan sonra her bir pikseli ifade eden 3 temel bileşeni içerek özellik vektörü
- Bir önceki maddede elde edilen özellik vektörüne LiDAR verisi de eklenerek elde edilen 4 uzunluğunda vektör.

Sınıflandırma için tasarlan tam bağlı katmanın tasarım bilgileri Tablo 7-1’de verilmektedir.

Sınıflandırma İçin Tasarlanan Tam Bağlı Sinir Ağı	
GİRDİ	[144], [145], [3], [4]
Tam Bağlı Katman 1 RELU	[144x128], [145x128], [3x128], [4x128] Nöron Sayısı : 128
Tam Bağlı Katman 2 RELU	[144x128], [145x128], [3x128], [4x128], Nöron Sayısı : 64
Tam Bağlı Katman 3 RELU	[144x128], [145x128], [3x128], [4x128], Nöron Sayısı : 32
Tam Bağlı Katman 4 RELU	[144x128], [145x128], [3x128], [4x128], Nöron Sayısı : 16
Çıktı Katmanı Softmax	[1x15]

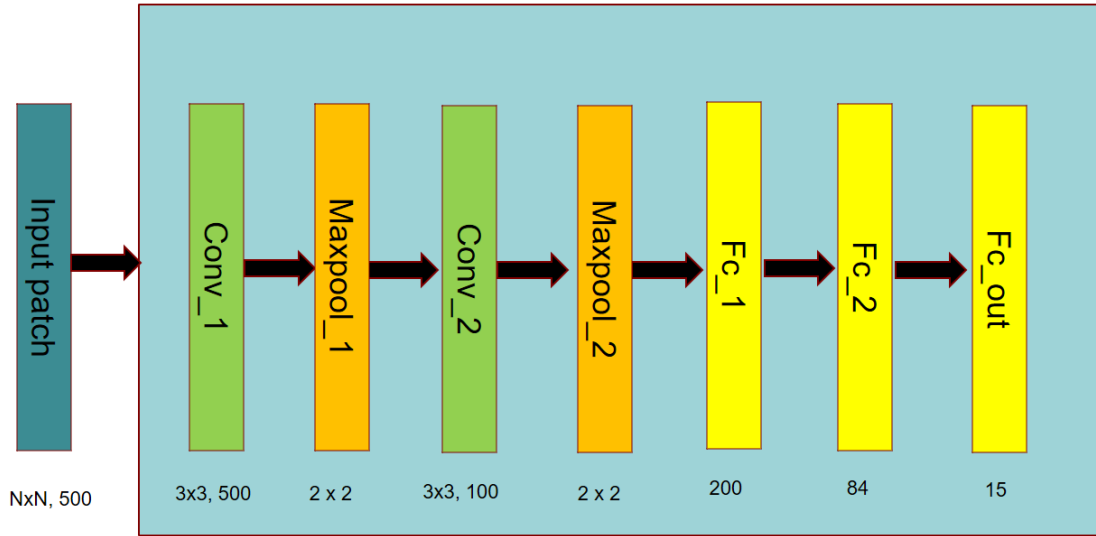
Tablo 7-1 : Sınıflandırma İçin Tasarlanan Tam Bağlı Sinir Ağı Tasarımı

7.3. SPEKTRAL VE UZAMSAL VERİ BERABER KULLANILARAK YAPILAN SINIFLANDIRMALAR

Bu yöntemde, sınıflandırma yöntemi olarak CNN kullanılmıştır. CNN ağına girdi 4 farklı şekilde verilmiştir. Bunlar:

- Hiperspektral görüntü üzerinde hedef piksel merkezde olacak şekilde küçük yamalar seçilerek CNN ağına girdi olarak verilmiştir.
- Hiperspektral görüntülerine LiDAR verisi de eklenerek, yukarıda bahsedildiği gibi yamaların seçilerek CNN ağına verilmiştir.
- Hiperspektral görüntülere TBA yapılarak elde edilen görüntülerden küçük yamalar seçilerek CNN ağına girdi olarak verilmiştir.
- Hiperspektral görüntülere TBA yapılarak elde edilen görüntülere LiDAR verisi de eklenerek elde edilen görüntüden küçük yamalar seçilerek CNN ağına girdi olarak verilmiştir.

Tasarlanan CNN ağının şematik gösterimi Şekil 7-2’de verilmiştir.



N : yama boyutu

Şekil 7-2 : Sınıflandırma için tasarlanan CNN ağı.

8. DENEYSEL SONUÇLARI

K En yakın komşu yöntemi deneyinin sonuçlarını Tablo 8-1’de görebilirsiniz.

Rastgele Orman sınıflandırma yöntemi kullanılarak yapılan deneylerin sonuçlarını Tablo 8-2’de görebilirsiniz.

Tam bağlı derin sinir ağı kullanılarak yapılan deney sonuçları Tablo 8-3’de görebilirsiniz.

Yama Tabanlı CNN deney sonuçlarını Tablo 8-4’te görebilirsiniz.

	K En Yakın Komşu Sınıflandırıcı			
	HSG	HSI + LiDAR	HSG_TBA	HSG TBA + LiDAR
OA	73 %	76 %	71 %	78 %
AA	75 %	79 %	70 %	78 %
Kappa	0.71	0.75	0.68	0.76

Tablo 8-1: KNN sınıflandırıcısı deney sonuçları

	Rastgele Orman Sınıflandırıcısı			
	HSG	HSG + LiDAR	HSG TBA	HSG TBA + LiDAR
OA	72 %	73 %	71 %	78 %
AA	75 %	76 %	71 %	77 %
Kappa	0.70	0.72	0.68	0.76

Tablo 8-2: Rastgele Orman sınıflandırıcısı deney sonuçları

	Tam Bağlı Derin Sinir Ağı			
	HSG	HSG + LiDAR	HSG_TBA	HSG_TBA+ LiDAR
OA	73 %	76 %	63 %	65 %
AA	75 %	75 %	64 %	69 %
Kappa	0.71	0.74	0.61	0.63

Tablo 8-3: Tam bağlı Derin Sinir Ağı deney sonuçları

	Yama Tabanlı CNN				
	HSI	HSI PCA	LiDAR	HSI+LiDAR	HSI PCA + LiDAR
OA	66 %	72 %	%42	%67	%75
AA	69 %	76 %	%45	%69	%76
Kappa	0.63	0.69	0.40	0.65	0.72

Tablo 8-4: Yama tabanlı CNN deney sonuçları

9. TARTIŞMA

Bu çalışma sonucunda elde edilen çıkarımlar şu şekildedir.

- Hiperspektral veriyle birlikte LiDAR verisinin kullanımı sınıflandırmanın başarımını önemli ölçüde artırmıştır.
- Spektral ve uzamsal veriyi beraber kullanarak yapılan sınıflandırma sonuçlarının, sadece spektral veriyi kullanan sınıflandırma sonuçlarına göre daha yüksek başarımlar elde ettiği görülmüştür.
- Hiperspektral ve LiDAR verilerini birleştirme yöntemlerinin sınıflandırma başarımlarını önemli ölçüde etkilediği görülmüştür.

Çalışmanın eksikleri ve gelecek projelerde yapılabilecekler şu şekildedir:

- Hiperspektral ve LiDAR verisini birleştirme yöntemleri geliştirilerek sınıflandırma başarımları artırılabilir.

10. KAYNAKLAR

- [1] Salman, Mesut, and Seniha Esen Yüksel. "Fusion of hyperspectral image and LiDAR data and classification using deep convolutional neural networks." *2018 26th Signal Processing and Communications Applications Conference (SIU)*. IEEE, **2018**.
- [2] Chen, Yushi, et al. "Deep fusion of remote sensing data for accurate classification." *IEEE Geoscience and Remote Sensing Letters* 14.8 (**2017**): 1253-1257.
- [3] Sabale, Savita P., and Chhaya R. Jadhav. "Hyperspectral Image Classification Methods in Remote Sensing-A Review." *Computing Communication Control and Automation (ICCUBEA), 2015 International Conference on*. IEEE, **2015**.
- [4] Luo, Renbo, et al. "Fusion of hyperspectral and LiDAR data for classification of cloud-shadow mixed remote sensed scene." *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing* 10.8 (**2017**): 3768-3781.
- [5] Chen, Yushi, et al. "Deep feature extraction and classification of hyperspectral images based on convolutional neural networks." *IEEE Transactions on Geoscience and Remote Sensing* 54.10 (**2016**): 6232-6251.